联邦学习梯度逆向攻击调研报告

张帅帅

2024 年 9 月 22 日

摘要

联邦学习（Federated Learning, FL）是一种分布式机器学习框架，允许用户在不共享原始数据的情况下，通过本地更新模型来共同训练全局模型。然而，尽管联邦学习在数据隐私保护方面具有显著优势，研究表明它仍然面临梯度逆向攻击（Gradient Inversion Attack）的隐私威胁。攻击者可以通过分析共享的模型梯度信息，重构用户的原始数据，导致严重的隐私泄露。本文介绍了梯度逆向攻击的工作原理，重点分析了三类主要的攻击方法：基于优化的攻击、基于GAN的攻击和基于恶意参数的攻击。同时，本文还总结了现有的防御策略，包括梯度剪枝、差分隐私和加密技术，以提高联邦学习系统的安全性。

目录

1 引言 **3**

2 联邦学习与隐私威胁 **3**

2.1 联邦学习概述 3

2.2 隐私泄露与安全风险 4

3 梯度逆向攻击 **4**

3.1 攻击原理 4

3.2 基于优化的攻击方法 7

3.3 基于GAN的攻击方法 8

3.4 基于恶意参数的攻击方法 8

4 梯度逆向攻击防御方法 **11**

4.1 参数加密 11

4.2 梯度裁剪 12

4.3 差分隐私 12

5 结论与展望 **12**

6 参考文献 **13**

1 引言

联邦学习（FL）作为一种分布式机器学习方法，已广泛应用于医疗、金融等需要高度数据隐私保护的领域。它通过让参与者在本地设备上进行模型训练，仅共享模型参数或梯度，以此避免敏感数据的泄露。然而，尽管联邦学习旨在保护用户隐私，梯度信息的共享仍然可能成为攻击的突破口，导致数据隐私的泄露。特别是梯度逆向攻击，利用神经网络的反向传播机制，通过分析参与者上传的梯度，攻击者可以重构原始数据。为了应对这种威胁，研究者提出了多种防御措施，本文将详细探讨梯度逆向攻击的技术原理、现有攻击手段及其防御策略。

2 联邦学习与隐私威胁

2.1 联邦学习概述

联邦学习（Federated Learning, FL）[18]是一种分布式机器学习框架，旨在让多个客户端在不泄露本地数据隐私的前提下合作训练一个全局模型。与传统的集中式学习方法不同，联邦学习允许多个参与方（如个人设备、组织）在本地保留数据，并在各自的设备上独立训练模型。各方只需将本地训练的模型更新（如梯度或参数）发送到中央服务器进行汇总，而不需要上传原始数据。服务器根据这些更新信息生成全局模型并再分发给各参与方，反复迭代以达到模型收敛，联邦学习的示意图如图1所示。联邦学习的核心优势在于保护数据隐私，特别适用于涉及敏感数据的场景，如医疗、金融和移动设备中的应用。

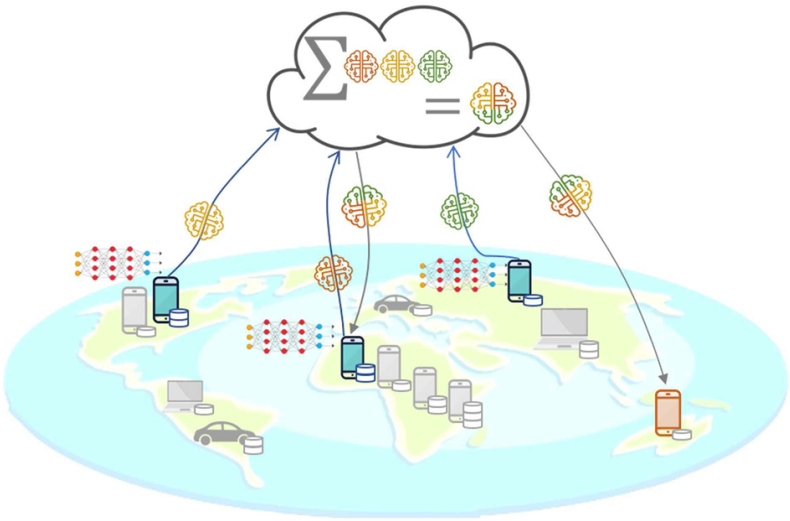

图 1: 联邦学习示意图

2.2 隐私泄露与安全风险

联邦学习虽然在数据隐私保护方面具有显著优势，但它仍然面临多种隐私攻击威胁。尽管参与方无需共享原始数据，联邦学习中的通信信息（如模型梯度或更新的参数）依然可能泄露敏感信息[16]，与隐私和安全相关的新挑战也随之出现。攻击者能够通过分析用户共享的模型更新数据，来推测与用户数据相关的隐私信息或者恢复出本地训练数据。现有的针对联邦学习的隐私攻击方法大致可以分为三类：**成员推理攻击**[20, 22]，**属性推理攻击**[7, 17]和**梯度逆向攻击**[30, 29, 9, 25, 27]。成员推理攻击旨在确定某一特定数据样本是否包含在用户的本地训练集中。一般来说，模型通常在训练过的样本上会表现得更加自信，即预测的置信度更高。攻击者通过比较模型对某个数据点的输出结果与其对未训练样本的输出结果，来推测该样本是否出现在训练集中。属性推理攻击的目标是推断训练样本中某些未公开的属性或特征，如某个人的年龄或性别等信息。梯度逆向攻击是联邦学习中特有的一类攻击，攻击者通过分析参与方上传的梯度信息，试图重构出完整的训练数据。该攻击主要是利用神经网络的反向传播机制，将梯度信息逆向传递，推测出原始输入数据。在这三类攻击方法中，成员推理攻击窃取的隐私信息最少，属性推理攻击次之，梯度逆向攻击对用户的数据隐私威胁最大。这些攻击方式表明，在联邦学习中，单纯依靠数据不离开本地的架构并不能完全避免隐私泄露，联邦学习需要结合差分隐私、加密技术等多种防御手段，来确保联邦学习系统的安全性与隐私保护。

3 梯度逆向攻击

3.1 攻击原理

在联邦学习中，每个参与方在本地使用自己的数据对共享的模型进行训练，使用反向传播算法计算模型的梯度。该梯度表示了模型对每个参数的调整方向和幅度，目的是通过这些梯度更新模型，使其对本地数据的预测更加准确。参与方需要将本地计算得到的梯度发送给中心服务器以更新全局模型，而共享的梯度数据极易被攻击者用于梯度逆向攻击（Gradient Inversion Attack，GIA），导致本地数据隐私的泄露。

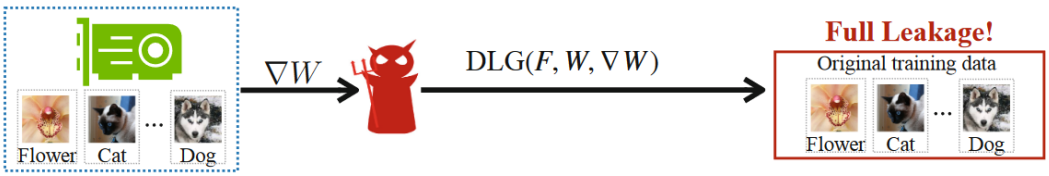

图 2: 联邦学习中的梯度逆向攻击

联邦学习中的梯度逆向攻击是一种通过分析模型训练过程中上传的梯度信息，反

推原始训练数据的攻击方法，如图2所示。梯度逆向攻击的核心思想是先假设梯度是由某一组输入数据产生的，然后模拟真实梯度的产生过程，通过迭代优化假设数据的方式使产生的梯度与真实梯度尽可能相似。由于神经网络梯度与输入数据密切相关，即单个数据点在该模型参数下产生的梯度数据往往是唯一的，那么攻击者可以通过不断优化缩小真假梯度之间的距离来得到真实的输入数据。

DLG[30]是较早提出且具有实际攻击效果的逆向攻击方法。下面详细介绍威胁模型和具体的攻击方法。

威胁模型：在联邦学习场景中，一个**诚实且好奇**的中心服务器协调多个客户训练一个全局模型F。其中一个客户利用本地数据$\boldsymbol{x}$计算得到梯度值$\nabla F(\boldsymbol{x}, \boldsymbol{W})$并发送给服务器。服务器尝试利用已知的数据（全局模型F、当前的模型参数$\boldsymbol{W}$以及梯度值$\nabla F(\boldsymbol{x}, \boldsymbol{W})$）去推测出原始的训练数据$\boldsymbol{x}$。

分析方法：我们从神经网络中最常见的全连接层（Fully Connected layer, FC）开始分析。对于有偏置参数的 FC 层，我们可以证明，无论层的位置在哪里，也无论前层和后层的类型如何，都可以通过梯度计算出相应的输入。

令神经网络中FC层的权重参数为$\boldsymbol{W} \in \mathbb{R}^{m \times n}$，偏置参数为$\boldsymbol{B} \in \mathbb{R}^{m}$，那么输入$\boldsymbol{X} \in \mathbb{R}^{n}$就可以得到对应的输出$\boldsymbol{Y} \in \mathbb{R}^{m}$为

$$\boldsymbol{Y} = \boldsymbol{W}\boldsymbol{X} + \boldsymbol{B} \tag{1}$$

根据神经网络的反向求导规则，对该层第i个神经元的参数$\boldsymbol{W}_i$和$\boldsymbol{B}_i$求导，就可以得到对应的梯度为

$$\frac{dL}{d\boldsymbol{W}_i} = \frac{dL}{d\boldsymbol{Y}_i} \cdot \frac{d\boldsymbol{Y}_i}{d\boldsymbol{W}_i} = \frac{dL}{d\boldsymbol{Y}_i} \cdot \boldsymbol{X}^T \tag{2}$$

$$\frac{dL}{d\boldsymbol{B}_i} = \frac{dL}{d\boldsymbol{Y}_i} \cdot \frac{d\boldsymbol{Y}_i}{d\boldsymbol{B}_i} = \frac{dL}{d\boldsymbol{Y}_i} \tag{3}$$

其中L为训练损失。两式相除，就可以直接得到原始的输入数据$\boldsymbol{X}$。如果是神经网络的第一层是FC层，那么利用该方法就可以从共享的梯度数据中直接恢复出本地的隐私训练数据。但是，该方法也有一定的局限性，必须要求该FC层采用了偏置参数且存在一个偏置参数的梯度$\frac{dL}{d\boldsymbol{B}_i} \neq 0$。

Gieping等人[9]对这种分析方法进一步分析，发现即使没有FC层没有偏置参数，也可以从梯度中恢复出输入数据。对于公式2,只需要知道$\frac{dL}{d\boldsymbol{Y}_i}$的值就可以求出输入$\boldsymbol{X}^T = (\frac{dL}{d\boldsymbol{Y}_i})^{-1} \cdot \frac{dL}{d\boldsymbol{W}_i}$。如果我们知道了损失$L$关于某一层的输入或输出的梯度，利用链式法则，就可以通过迭代计算得到第一层的输入数据。这就好比在神经网络的反向传播中找到一条到达最后一层的通路，这条路径上的所有参数的梯度都不为0，就能够让攻击者恢复出隐私训练数据。Pan[21]等人提出的梯度逆向攻击方法也是类似的思路，如图3所示。

这种针对梯度数据的分析方法能直接从FC层的梯度数据中恢复输入数据，主要依靠FC层的参数维度和输入数据一致。但是，这种方法难以拓展到卷积层（Convolutiona layer, Conv）中，有两个原因：

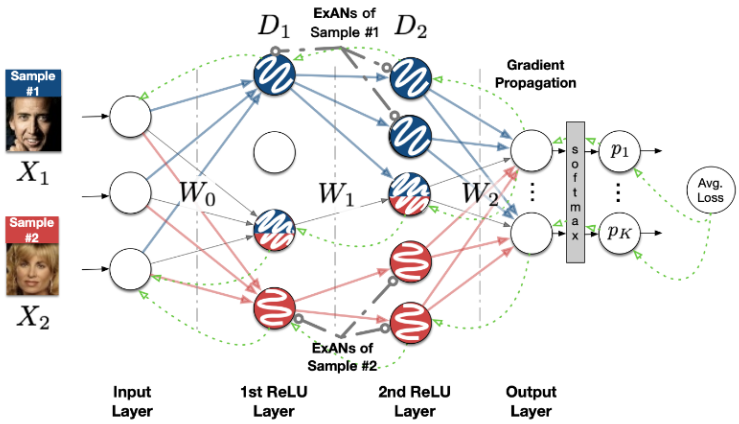

图 3: 通过迭代分析逆向训练数据

（1） Conv层依靠卷积核与输入相乘，单个卷积核的参数量一般为3×3或者5×5，远远小于输入数据的维度。

（2） 卷积核的每个参数都要与输入的每一个维度相乘，所以该参数的梯度是输入数据所有维度的叠加，这种混合导致无法恢复出原始数据每个维度的准确数值。

优化方法：为了从基于Conv的神经网络梯度中恢复原始数据，DLG[9]提出了一种基于迭代优化的梯度逆向攻击方法。核心思路是模拟本地训练过程产生一个假梯度，通过不断调整构造的数据，使真假梯度的距离尽可能小。不断优化直到收敛，就能成功恢复出输入Conv网络的隐私训练数据。

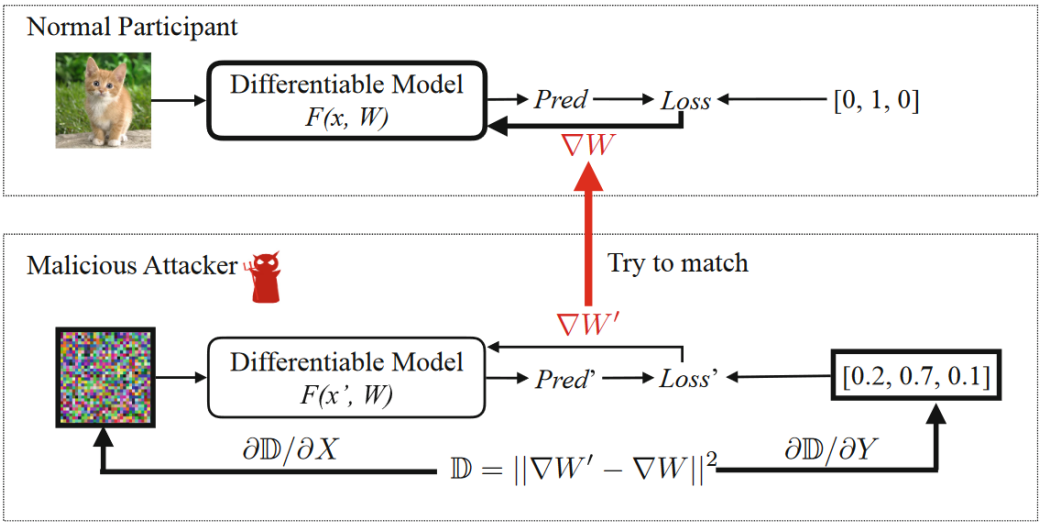

图 4: DLG攻击算法

DLG的攻击算法流程图如图4所示。具体的攻击步骤如下：

(1) 随机初始化假数据和标签$(\boldsymbol{x}', y')$

(2) 利用已知的模型参数$\boldsymbol{W}$计算假梯度$\nabla \boldsymbol{W}' = \frac{\partial l(F(\boldsymbol{x}', \boldsymbol{W}), y')}{\partial \boldsymbol{W}}$

(3) 计算假梯度$\nabla \boldsymbol{W}'$和真梯度$\nabla \boldsymbol{W}$之间的距离$\mathbb{D} = \|\nabla \boldsymbol{W}' - \nabla \boldsymbol{W}\|^2$

(4) 计算梯度优化假数据和标签

$$\boldsymbol{x}' \leftarrow \boldsymbol{x}' - \eta \nabla_{\boldsymbol{x}'} \mathbb{D} \tag{4}$$

$$y' \leftarrow y' - \eta \nabla_{y'} \mathbb{D} \tag{5}$$

(5) 重复步骤（2）到（4）直到距离$\mathbb{D}$最小

DLG通过不断优化假数据使其产生的假梯度尽可能与真实梯度相似，若成功收敛，就能重构隐私训练数据，效果如图5所示。

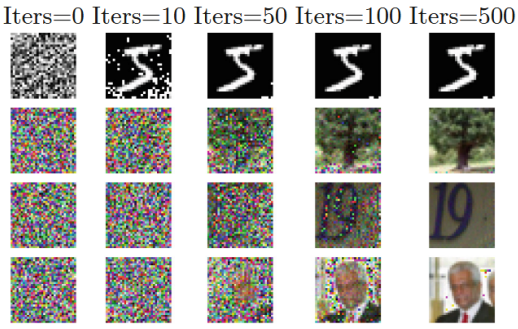

图 5: DLG的攻击效果

3.2 基于优化的攻击方法

DLG这类基于优化的攻击方法通过最小化公式6来恢复原始隐私数据和标签，而后续的很多工作都是在DLG的基础上进行改进，不断提升DLG的攻击效果和通用性。

$$\boldsymbol{x}^*, y^* = arg \min_{\boldsymbol{x}', y^*} \|\nabla_{\boldsymbol{W}} l(x, y) - \nabla_{\boldsymbol{W}} l(x', y')\|^2 \tag{6}$$

标签问题 在标签数据未知的情况下优化公式6难以收敛，zhao等人[29]提出了iDLG方法，通过分析的方法从真实梯度数据中提取出真实的标签信息。具体而言，分类训练采用的都是交叉损失熵函数:

$$l(\boldsymbol{x}, c) = -\log \frac{e^{\boldsymbol{Y}_c}}{\sum_j e^{\boldsymbol{Y}_j}} \tag{7}$$

那么，相应的梯度就是

$$g_i = \frac{\partial l(\boldsymbol{x}, c)}{\partial \boldsymbol{Y}_i} = \begin{cases} -1 + \dfrac{e^{\boldsymbol{Y}_i}}{\sum_j e^{\boldsymbol{Y}_j}}, if \quad i == c \\ \dfrac{e^{\boldsymbol{Y}_i}}{\sum_j e^{\boldsymbol{Y}_j}}, else \end{cases} \tag{8}$$

从上式可以发现，真实标签对应的梯度是负值，其他的都是正值，这种差异就可以帮助攻击者直接确定恢复数据的真实标签。

损失函数 DLG攻击方法采用L-BFGS算法来优化公式6，虽然L-BFGS优化速度快，但是需要求损失的二阶导数，也就是原函数参数的三阶导数。这就要求原模型是可微的，但是大部分模型采用的都是Relu激活函数，求三次导数后都为0。这种高阶导数的不连续性，导致DLG方法无法攻击使用ReLU激活函数的模型。

Geiping等人[9]提出利用余弦函数计算真假梯度的距离，并使用Adam优化构造的数据。

$$\arg\min_{x} 1 - \frac{< \nabla_\theta \mathcal{L}_\theta(x,y), \nabla_\theta \mathcal{L}_\theta(x^*,y) >}{\|\nabla_\theta \mathcal{L}_\theta(x,y)\|^2 \cdot \|\nabla_\theta \mathcal{L}_\theta(x^*,y)\|^2} + \alpha TV(x) \tag{9}$$

梯度数据都是高维矢量，采用余弦距离可以更关注于真假梯度的方向差异。附加的TV损失则是添加了对真实数据的先验知识，使恢复数据的像素与周边像素更具有连续性。改进后的DLG攻击效果如图6所示。

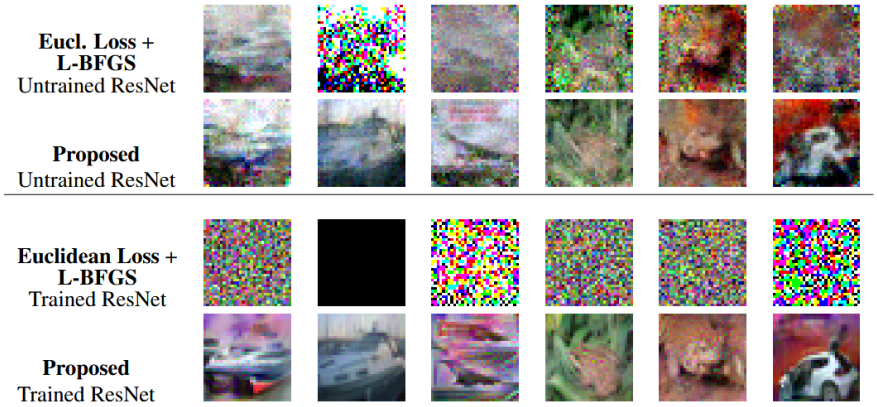

图 6: DLG攻击算法

3.3 基于GAN的攻击方法

为了提升重构数据的质量，[11, 24, 14]等方法将GAN网络应用到梯度逆向攻击中。基本思路就是使用预训练好的GAN网络生成假数据，然后类似DLG计算真假梯度的距离，依据该距离损失去优化构造的数据，如图7所示。唯一的区别是，基于GAN的攻击方法优化的是输入GAN网络的数据，而DLG是直接优化构造数据本身。预训练GAN网络中的先验知识可以有效提升逆向攻击的稳定性和攻击效果。

3.4 基于恶意参数的攻击方法

上述的两类梯度逆向攻击方法都属于被动式攻击，即攻击者只利用可以获得的数据去逆向隐私数据。但是，当用户采用更大的batchsize或者更多的本地训练迭代时，共

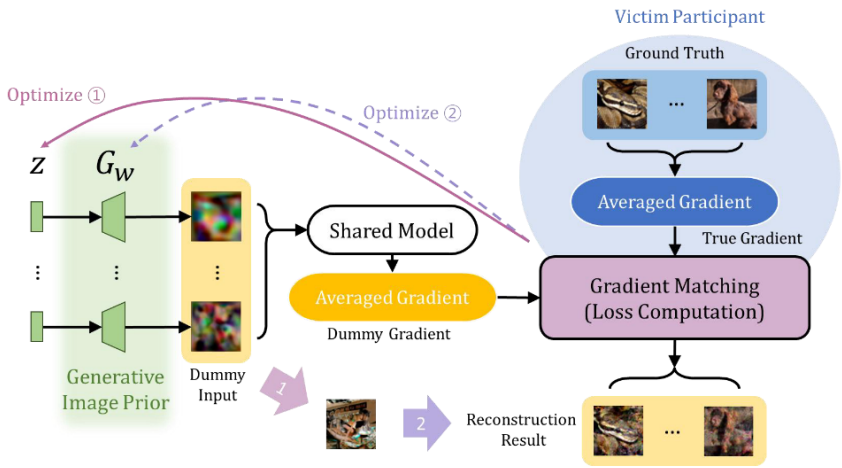

图 7: 基于GAN的梯度逆向攻击算法

享的梯度数据就存在严重的**梯度混淆**，这会大大降低上述的被动式梯度逆向攻击方法的攻击效果。在公式2中，神经元的梯度只和单个数据相关，所以攻击者可以利用分析的方法直接逆向出训练数据。但是，梯度混淆使得单个神经元的梯度与多个训练数据相关，如果依然使用分析方法，那么得到的恢复数据就如公式10所示。我们发现，这种情况下逆向出来的数据是多个训练数据的线性叠加，这种叠加保护了单个数据的隐私。为了放大共享梯度的隐私泄露程度，最近的研究热点[6, 26, 2]转向了主动式逆向攻击，攻击者可以通过发送恶意参数等方法去干扰本地的模型训练过程,恶意参数的目标就是抑制**梯度混淆**现象，即尽可能让单个神经元的梯度只与单个数据相关。

$$\tilde{x} = \frac{\partial \mathcal{L}}{\partial w_i^T} \cdot (\frac{\partial \mathcal{L}}{\partial b_i})^{-1} = \sum_{j=1}^{N} \alpha_j x_j \tag{10}$$

$$\alpha_j = \frac{\partial \mathcal{L}}{\partial y_{i,j}} \cdot (\sum_{n=1}^{N} \frac{\partial \mathcal{L}}{\partial y_{i,n}})^{-1} \tag{11}$$

威胁模型：该类攻击方法假设了一个能力更强的攻击者，可以是恶意的客户端或者中心服务器，他们可能不遵守FL的协定，可以篡改发送的数据，同时利用已知的数据（全局模型F、当前的模型参数$\boldsymbol{W}$以及梯度值$\nabla F(\boldsymbol{x}, \boldsymbol{W})$）去推测出原始的训练数据$\boldsymbol{x}$。

Fowl等人[6]最先提出了基于恶意参数的主动式梯度逆向攻击方法。3.1节中的分析方法发现，在FC层中存在部分特殊神经元，他们的梯度只与单个数据相关，那么该隐私数据就可以直接由梯度数据反推出来。我们称这类神经元为**单数据激活神经元**，在正常网络中的这类神经元很少。为了提升单数据激活神经元的数量，Fowl等人设计了一个嵌入模块，根据累计密度函数设定特殊的模型参数，并将该模块嵌入到全局模型中。当用户进行本地模型训练的时候，该嵌入模块上的梯度数据仅与单个数据相关，攻击者可

以直接重构出隐私训练数据。

Fowl等人[6]的攻击方法需要修改全局模型，在实际情况中难以实现并且容易被发现。Wen等人[26]便提出了模型不变，只需要修改参数的攻击方法。恶意参数$W_{i,j}, b_i$的设置方法如下：

$$W_{i,j} = \begin{cases} \beta, if \quad i = c \quad and \quad j = k \\ 0, otherwise \end{cases} \tag{12}$$

$$b_i = \begin{cases} -\beta * \theta, if \quad i = c \\ 0, otherwise \end{cases} \tag{13}$$

，其中θ和β是攻击者设置的两个超参数，用来筛选目标数据的类别和属性。通过这种参数设置，就可以使用户在进行本地训练时，隔离部分数据的梯度回传，目标数据的梯度在共享梯度中占比最大，如图8所示。

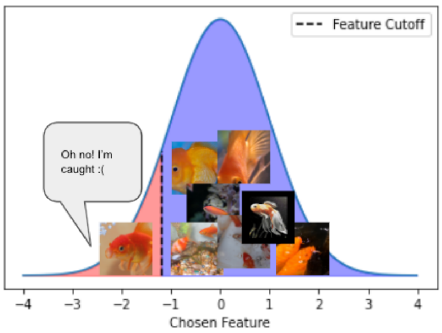

图 8: 通过恶意参数阻碍部分数据的梯度

上述两种方法在一次攻击中只能恢复一个batch中的部分或少量数据。Boenisch等人[2]则提出了一种能同时重构整个batch的恶意参数设置方法。他们利用高斯分布初始化FC层参数，然后随机选择部分神经元，对其参数进行放缩和随机排列。这样就可以使模型的第一层FC中出现大量的单数据激活神经元，他们的梯度只与某个数据相关，利用分析方法可以完美重构隐私数据，如图9所示。

隐蔽性是影响基于恶意参数的攻击方法能否成功的重要因素。上述的恶意参数构成都存在一定规律，要么存在大量的参数为0，要么服从高斯分布，这导致客户端很容易检测到模型参数被恶意篡改了。为了提升恶意参数的隐蔽性，Garov等人[8]结合优化方法提出了SEER，通过训练来生成恶意参数，攻击思路如图10所示。他们分别训练了全局模型θ_f、梯度分解模型θ_d和重构模型θ_r。基于θ_f训练得到的混合梯度可以通过θ_d进行拆分，从混合梯度中提取出与指定数据相关联的梯度，然后利用重构模型θ_r复现出隐私训练数据。

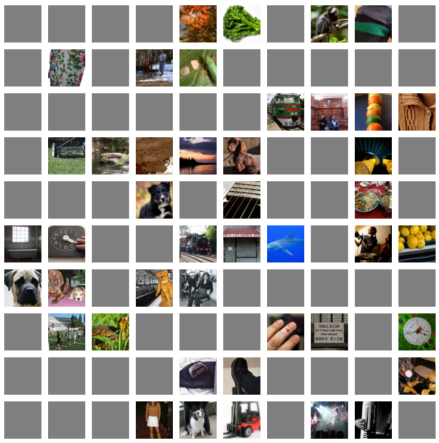

图 9: 利用FC中的单数据激活神经元可以完美重构隐私数据

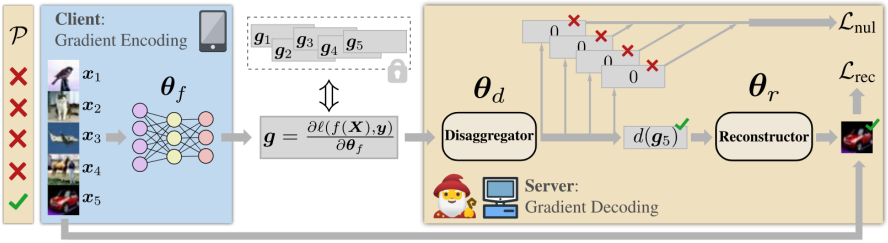

图 10: 逆向攻击方法SEER

综上所述，采取主动攻击的目的就是利用恶意参数削弱梯度混淆程度。当得到的梯度数据仅与单个数据相关时，攻击者就能够通过分析或者优化的方法成功重构隐私训练数据。

4 梯度逆向攻击防御方法

4.1 参数加密

对共享的梯度数据进行加密处理是防御各类隐私攻击最安全的方式，只要攻击者无法获得详细的梯度数据，用户的隐私就不会发生泄露。一种参数加密方法是利用同态加密（Homomorphic Encryption）技术。同态加密允许在密文状态下进行数学运算，服务器无需解密即可对加密后的梯度进行聚合。这样，参与者的梯度在传输和处理过程中始终保持加密状态，避免泄露。具体的加密和解密过程是参与者在本地计算完梯度后，使用同态加密技术将其加密后上传到服务器。服务器在密文下执行加法操作（如梯度聚合），最后参与者通过密钥解密获得更新后的全局模型。但是，同态加密技术会导致很高的计算开销和通信成本，尤其是当模型复杂或参与者数量较多时，可能会显著影响系统的效率。另一种参数加密方法是采用安全多方计算（Secure Multi-Party

Computation, SMPC），SMPC是一种允许多个参与者在不泄露各自数据的情况下共同计算某一函数值的技术。每个参与者将梯度信息分成若干份，并分发给其他参与者。服务器收集到所有碎片后，能够恢复出全局梯度，但攻击者无法从中获取有效的个体梯度信息。与同态加密类似，SMPC的计算和通信开销较高，尤其在参与者数量较多时，系统复杂性显著增加。

4.2 梯度裁剪

梯度剪枝是一种通过削减梯度信息来减少泄露风险的防御技术。它通过移除梯度中较不重要或值较小的部分，限制攻击者能利用的有效信息。这种经过裁剪稀疏的梯度数据，与原始训练数据的关联性被削弱，基于优化的DLG等攻击方法难以收敛，可以有效防止隐私泄露。Zhu等人[30]测试过梯度裁剪对梯度逆向的防御效果，发现当裁剪比例超过30%就能有效防御逆向攻击。但是，如果裁剪阈值过大，就会导致FL中全局模型的性能下降。

4.3 差分隐私

差分隐私（Differential Privacy）[4, 5]是一种广泛用于保护数据隐私的技术，通过在数据或梯度中引入噪声来打乱信息，从而使攻击者难以重构原始数据。在联邦学习中，差分隐私主要通过在本地计算梯度后，上传到中央服务器之前，添加噪声来实现隐私保护。将差分隐私引入联邦学习，可以提供**样本级DP保证**[1, 23, 12]或者是**客户端级DP保证**[10, 19, 15, 31, 3]。一种常用的实现客户端级DP保证的方法是基于**高斯机制**处理本地更新，首先对本地更新Δ_i^t进行裁剪，然后再加入高斯噪音：

$$\widetilde{\Delta}_i^t = \Delta_i^t / \max(1, \frac{||\Delta_i^t||_2}{S}) + \mathcal{N}(0, \frac{\sigma^2 S^2 \mathbf{I}_d}{|\mathcal{C}_t|}) \tag{14}$$

其中S是裁剪阈值，σ是噪音系数，$|\mathcal{C}_t|$参与本轮学习的用户数量。虽然增加噪音大小可以提高隐私性，但是随机噪音的引入会导致模型性能的下降，如何权衡隐私性和可用性依然是一个研究热点。Cheng等人[3]提出利用正则化减小更新的L_2模长，这样能够减少本地更新在裁剪操作中的偏差，从而提升模型准确率。Zhang等人[28]从收敛性的角度分析了L_2裁剪对模型性能的影响，给出了可靠的理论分析。Hu等人[13]则提出结合梯度裁剪技术，先对本地更新进行稀疏，然后再添加差分隐私噪音。这样可以有效降低模型更新的维度，从而减少加入的噪音总量，实验表明在相同的隐私保护性能下该方法可以显著提高模型性能。

5 结论与展望

虽然现有的防御方法如差分隐私、同态加密和梯度剪枝能够在一定程度上缓解梯

度逆向攻击的风险，但它们仍存在性能下降、计算和通信开销大等局限性。未来研究需要重点关注以下几个方向：一是提高防御策略的效率，特别是在保持隐私保护效果的同时，降低对模型性能的影响；二是探索能够同时应对多种隐私攻击的综合防御方法；三是针对不同场景和应用开发自适应的防御机制。随着联邦学习的不断发展，隐私保护和安全性问题仍将是未来研究的重点。

6 参考文献

参考文献

[1] Martin Abadi, Andy Chu, Ian Goodfellow, H Brendan McMahan, Ilya Mironov, Kunal Talwar, and Li Zhang. Deep learning with differential privacy. In *Proceedings of the 2016 ACM SIGSAC conference on computer and communications security*, pages 308–318, 2016.

[2] Franziska Boenisch, Adam Dziedzic, Roei Schuster, Ali Shahin Shamsabadi, Ilia Shumailov, and Nicolas Papernot. When the Curious Abandon Honesty: Federated Learning Is Not Private. *arXiv:2112.02918 [cs]*, 2021.

[3] Anda Cheng, Peisong Wang, Xi Sheryl Zhang, and Jian Cheng. Differentially private federated learning with local regularization and sparsification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10122–10131, 2022.

[4] Cynthia Dwork. Differential privacy. In *Automata, Languages and Programming: 33rd International Colloquium, ICALP 2006, Venice, Italy, July 10-14, 2006, Proceedings, Part II 33*, pages 1–12. Springer, 2006.

[5] Cynthia Dwork, Aaron Roth, et al. The algorithmic foundations of differential privacy. *Foundations and Trends® in Theoretical Computer Science*, 9(3–4):211–407, 2014.

[6] Liam Fowl, Jonas Geiping, Wojtek Czaja, Micah Goldblum, and Tom Goldstein. Robbing the Fed: Directly Obtaining Private Data in Federated Learning with Modified Models. *arXiv:2110.13057 [cs]*, 2022.

[7] Karan Ganju, Qi Wang, Wei Yang, Carl A. Gunter, and Nikita Borisov. Property Inference Attacks on Fully Connected Neural Networks using Permutation Invariant

Representations. In *Proceedings of the 2018 ACM SIGSAC Conference on Computer and Communications Security*, CCS '18, pages 619–633, New York, NY, USA, 2018. Association for Computing Machinery.

[8] Kostadin Garov, Dimitar I Dimitrov, Nikola Jovanović, and Martin Vechev. Hiding in plain sight: Disguising data stealing attacks in federated learning. *arXiv preprint arXiv:2306.03013*, 2023.

[9] Jonas Geiping, Hartmut Bauermeister, Hannah Dröge, and Michael Moeller. Inverting gradients-how easy is it to break privacy in federated learning? *Advances in Neural Information Processing Systems*, 33:16937–16947, 2020.

[10] Robin C Geyer, Tassilo Klein, and Moin Nabi. Differentially private federated learning: A client level perspective. *arXiv preprint arXiv:1712.07557*, 2017.

[11] Briland Hitaj, Giuseppe Ateniese, and Fernando Perez-Cruz. Deep models under the gan: information leakage from collaborative deep learning. In *Proceedings of the 2017 ACM SIGSAC conference on computer and communications security*, pages 603–618, 2017.

[12] Rui Hu, Yanmin Gong, and Yuanxiong Guo. Federated learning with sparsification-amplified privacy and adaptive optimization. *arXiv preprint arXiv:2008.01558*, 2020.

[13] Rui Hu, Yuanxiong Guo, and Yanmin Gong. Federated learning with sparsified model perturbation: Improving accuracy under client-level differential privacy. *IEEE Transactions on Mobile Computing*, 2023.

[14] Jinwoo Jeon, Kangwook Lee, Sewoong Oh, Jungseul Ok, et al. Gradient inversion with generative image prior. *Advances in neural information processing systems*, 34:29898–29908, 2021.

[15] Peter Kairouz, Ziyu Liu, and Thomas Steinke. The distributed discrete gaussian mechanism for federated learning with secure aggregation. In *International Conference on Machine Learning*, pages 5201–5212. PMLR, 2021.

[16] Peter Kairouz, H Brendan McMahan, Brendan Avent, Aurélien Bellet, Mehdi Bennis, Arjun Nitin Bhagoji, Kallista Bonawitz, Zachary Charles, Graham Cormode, Rachel Cummings, et al. Advances and open problems in federated learning. *Foundations and Trends® in Machine Learning*, 14(1–2):1–210, 2021.

[17] Saeed Mahloujifar, Esha Ghosh, and Melissa Chase. Property inference from poisoning. In *2022 IEEE Symposium on Security and Privacy (SP)*, pages 1569–1569, 2022.

[18] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-Efficient Learning of Deep Networks from Decentralized Data. In *Artificial Intelligence and Statistics*, pages 1273–1282. PMLR, 2017.

[19] H Brendan McMahan, Daniel Ramage, Kunal Talwar, and Li Zhang. Learning differentially private recurrent language models. *arXiv preprint arXiv:1710.06963*, 2017.

[20] Luca Melis, Congzheng Song, Emiliano De Cristofaro, and Vitaly Shmatikov. Exploiting Unintended Feature Leakage in Collaborative Learning. In *2019 IEEE Symposium on Security and Privacy (SP)*, pages 691–706, 2019.

[21] Xudong Pan, Mi Zhang, Yifan Yan, Jiaming Zhu, and Zhemin Yang. Exploring the security boundary of data reconstruction via neuron exclusivity analysis. In *31st USENIX Security Symposium (USENIX Security 22)*, pages 3989–4006, 2022.

[22] Reza Shokri, Marco Stronati, Congzheng Song, and Vitaly Shmatikov. Membership Inference Attacks Against Machine Learning Models. In *2017 IEEE Symposium on Security and Privacy (SP)*, pages 3–18, 2017.

[23] Florian Tramer and Dan Boneh. Differentially private learning needs better features (or much more data). *arXiv preprint arXiv:2011.11660*, 2020.

[24] Zhibo Wang, Mengkai Song, Zhifei Zhang, Yang Song, Qian Wang, and Hairong Qi. Beyond inferring class representatives: User-level privacy leakage from federated learning. In *IEEE INFOCOM 2019-IEEE conference on computer communications*, pages 2512–2520. IEEE, 2019.

[25] Wenqi Wei, Ling Liu, Margaret Loper, Ka-Ho Chow, Mehmet Emre Gursoy, Stacey Truex, and Yanzhao Wu. A framework for evaluating client privacy leakages in federated learning. In *Computer Security–ESORICS 2020: 25th European Symposium on Research in Computer Security, ESORICS 2020, Guildford, UK, September 14–18, 2020, Proceedings, Part I 25*, pages 545–566. Springer, 2020.

[26] Yuxin Wen, Jonas Geiping, Liam Fowl, Micah Goldblum, and Tom Goldstein. Fishing for user data in large-batch federated learning via gradient magnification. *arXiv preprint arXiv:2202.00580*, 2022.

[27] Hongxu Yin, Arun Mallya, Arash Vahdat, Jose M Alvarez, Jan Kautz, and Pavlo Molchanov. See through gradients: Image batch recovery via gradinversion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16337–16346, 2021.

[28] Xinwei Zhang, Xiangyi Chen, Mingyi Hong, Zhiwei Steven Wu, and Jinfeng Yi. Understanding clipping for federated learning: Convergence and client-level differential privacy. In *International Conference on Machine Learning, ICML 2022*, 2022.

[29] Bo Zhao, Konda Reddy Mopuri, and Hakan Bilen. iDLG: Improved Deep Leakage from Gradients. *arXiv:2001.02610 [cs, stat]*, 2020.

[30] Ligeng Zhu and Song Han. Deep Leakage from Gradients. In *Federated Learning: Privacy and Incentive*, Lecture Notes in Computer Science, pages 17–31. Springer International Publishing, Cham, 2020.

[31] Yuqing Zhu, Xiang Yu, Yi-Hsuan Tsai, Francesco Pittaluga, Masoud Faraki, Yu-Xiang Wang, et al. Voting-based approaches for differentially private federated learning. *arXiv preprint arXiv:2010.04851*, 2020.